

Descripción del modelo de aprendizaje no supervisado

Proyecto: Sistema Inteligente de Rutas

Actividad: agrupamiento de rutas mediante K-Means

1. Objetivo

Aplicar una técnica de aprendizaje no supervisado para agrupar registros de rutas según sus características numéricas, sin utilizar la etiqueta supervisada **ruta_recomendada** como variable de entrada. El propósito es explorar similitudes entre rutas y describir los grupos encontrados.

2. Datos utilizados

El programa carga el conjunto de datos a través de **RUTA_DATOS**, definida en **ml/configuracion.py**. El dataset usado por las pruebas contiene 170 registros. El proyecto describe estos datos como académicos y parcialmente sintéticos; no deben interpretarse como mediciones operacionales reales del transporte.

3. Variables de agrupamiento

Variable	Descripción
distancia_km	Distancia de la ruta en kilómetros.
numero_estaciones	Número de estaciones.
numero_transbordos	Número de transbordos.
nivel_congestion	Nivel de congestión registrado en el dataset.
tiempo_estimado_min	Tiempo estimado en minutos.
costo_estimado	Costo estimado.
hora_pico	Indicador de hora pico.

La columna **ruta_recomendada** se excluye expresamente del agrupamiento. Esto evita introducir la etiqueta objetivo de la actividad supervisada en el modelo no supervisado.

4. Preparación y metodología

La función **cargar_datos()** comprueba que existan las columnas necesarias y que no haya valores nulos en las variables seleccionadas. La función **preparar_datos()** aplica **StandardScaler** para estandarizar las siete variables.

La función **evaluar_k()** evalúa $K = 2, 3, 4, 5$ y 6 . Para cada valor calcula la inercia del modelo y el coeficiente silhouette. La implementación utiliza KMeans con **random_state=42** y **n_init=20**. El valor final configurado es **K_SELECCIONADO = 2**.

5. Visualizaciones y resultados guardados

El script genera tres archivos: **graficas/metodo_codo.png** (inercia frente a K), **graficas/silhouette_clusters.png** (coeficiente silhouette frente a K) y **graficas/clusters_rutas.png** (representación bidimensional mediante PCA). PCA se usa para visualizar los datos en dos componentes; el agrupamiento se entrena con las siete variables estandarizadas.

La función **guardar_resultados()** escribe **datos/rutas_agrupadas.csv**, que conserva las columnas originales y añade la columna **cluster**.

6. Interpretación y limitaciones

Los números de cluster son etiquetas técnicas, no categorías oficiales de transporte. Para describir cada grupo se calcula el promedio de las siete variables mediante **crear_perfil_clusters()**. Las diferencias observadas deben interpretarse como patrones del dataset académico; no prueban que los grupos se comporten igual en una red real.

7. Ejecución

Desde la raíz del repositorio, ejecutar:

```
python ml/agrupar_rutas.py
```

El script carga y valida los datos, estandariza las variables, evalúa K, genera las gráficas, asigna los clusters, guarda el CSV agrupado e imprime el perfil medio de los grupos.