

Descripción y procedencia de los datos

Rodrigo Bonilla Torres

Gispy Dayanna Páez Cañon

Inteligencia artificial

Sandra Bautista

Corporación Universitaria Iberoamericana

Bogotá, Colombia

8, octubre de 2026

Tabla de contenido

1.	Objetivo.....	3
2.	Procedencia y alcance	4
3.	Diccionario de datos	4
4.	Generación y reproducibilidad.....	4
5.	Construcción de la etiqueta.....	4
6.	Distribución obtenida.....	4
7.	Uso en el entrenamiento.....	5
8.	Limitaciones y responsabilidad.....	5
9.	Archivos y comandos de referencia	5

1. Objetivo

Describir las fuentes, variables, reglas de generación y características del conjunto de datos utilizado para entrenar un clasificador de rutas de transporte mediante aprendizaje supervisado.

2. Procedencia y alcance

El proyecto utiliza un conjunto de datos sintético elaborado con fines académicos. Se parte de 20 registros base conservados en `datos/rutas_base.csv` y se generan 150 registros adicionales con `datos/generar_dataset.py`. El archivo resultante `datos/rutas_transporte.csv` contiene 170 registros y nueve columnas. No se utilizaron registros operacionales ni etiquetas reales de TransMilenio.

3. Diccionario de datos

Campo	Significado / escala
<code>distancia_km</code>	Distancia simulada de la ruta (km)
<code>numero_estaciones</code>	Cantidad simulada de estaciones.
<code>numero_transbordos</code>	Cantidad simulada de transbordos
<code>nivel_congestion</code>	Nivel de congestión simulado (1 a 5)
<code>tiempo_estimado_min</code>	Duración estimada en minutos
<code>costo_estimado</code>	Costo estimado en unidades académicas, no tarifa real
<code>hora</code>	Hora simulada del recorrido (HH:MM)
<code>hora_pico</code>	Indicador binario de periodo pico: 0 o 1
<code>ruta_recomendada</code>	Etiqueta objetivo: 0 = no recomendada; 1 = recomendada

4. Generación y reproducibilidad

El generador usa la semilla pseudoaleatoria 42. Primero recupera los 20 registros originales y conserva las horas definidas para ellos; después crea 150 observaciones adicionales mediante relaciones simuladas entre distancia, estaciones, transbordos, congestión, tiempo y costo. Los horarios pico académicos se definen de 06:00 a 09:00 y de 16:00 a 19:00, con ambos extremos incluidos. Ejecutar el generador vuelve a construir el CSV desde el archivo base, evitando acumulaciones al repetir el proceso.

5. Construcción de la etiqueta

Para los registros nuevos se calcula un puntaje sintético que pondera el tiempo estimado, el costo, los transbordos, la congestión y el indicador de hora pico. Un puntaje menor favorece la recomendación. El umbral se obtiene de los puntajes centrales de las 150 observaciones nuevas y se añade una variación aleatoria pequeña. Las 20 etiquetas originales se preservan del archivo base. Por tanto, el modelo aprende patrones definidos por esta simulación, no preferencias verificadas de pasajeros.

6. Distribución obtenida

Indicador	Valor
Registros originales	20
Registros adicionales	150
Total	170
Columnas	9
Rutas recomendadas (1)	86
Rutas no recomendadas (0)	84

7. Uso en el entrenamiento

El clasificador emplea siete predictores: `distancia_km`, `numero_estaciones`, `numero_transbordos`, `nivel_congestion`, `tiempo_estimado_min`, `costo_estimado` y `hora_pico`. La variable `hora` se conserva en el CSV, pero no entra directamente al árbol. La etiqueta de salida es `ruta_recomendada`. Se reserva el 30 % para evaluación estratificada (51 registros) y el 70 % para entrenamiento (119 registros).

8. Limitaciones y responsabilidad

Los valores de distancia, tiempo, congestión y costo no deben interpretarse como información real del sistema de transporte. La exactitud obtenida evalúa el desempeño frente a etiquetas sintéticas. No se demuestra capacidad de recomendación sobre recorridos reales ni se integra el clasificador con el motor de búsqueda A*. Para aplicación práctica se requerirían datos reales, etiquetas independientes, validación adicional y revisión de posibles sesgos.

9. Archivos y comandos de referencia

- Archivos: `datos/rutas_base.csv`, `datos/generar_dataset.py` y `datos/rutas_transporte.csv`.
Comando de generación: `py datos/generar_dataset.py`.
- Repositorio: github.com/r0odr1/Sistema-Inteligente-de-Rutas.