

Métodos de aprendizaje supervisado

Rodrigo Bonilla Torres
Gispy Dayanna Páez Cañon

Inteligencia artificial
Sandra Bautista

Corporación Universitaria Iberoamericana
Bogotá, Colombia
8, octubre de 2026

Tabla de contenido

1. Objetivo.....	4
2. Configuración del experimento.....	4
3. Resultados de la evaluación	4
4. Métricas por clase	4
5. Importancia de las características	4
6. Evidencias gráficas	5
7. Prueba de predicción.....	5
8. Pruebas automatizadas	5
9. Interpretación y limitaciones.....	5
10. Conclusiones	6
11. Referencias y ejecución	6

1. Objetivo

Verificar el funcionamiento del componente de aprendizaje supervisado del proyecto, desde la carga de datos hasta el entrenamiento, la evaluación y la predicción de una nueva ruta, conservando la compatibilidad con el sistema previo de búsqueda A*.

2. Configuración del experimento

Elemento	Configuración
Algoritmo	DecisionTreeClassifier (scikit-learn)
Profundidad máxima	4
Semilla aleatoria	42
Conjunto de datos	170 registros sintéticos
Entrenamiento / prueba	119 / 51 (70 % / 30 %, estratificado)
Características predictoras	7
Clases	No recomendada (0) y Recomendada (1)

3. Resultados de la evaluación

La ejecución del comando `py -m ml.entrenar_modelo` reportó una exactitud del 92,16 % sobre 51 registros de prueba. De ellos, 47 fueron clasificados correctamente y cuatro incorrectamente.

Clase real /Predicción	No recomendada	Recomendada
No recomendada	24	1
Recomendada	3	23

La matriz de confusión muestra 24 aciertos para la clase no recomendada y 23 para la clase recomendada. Hubo un falso positivo de recomendación y tres rutas recomendadas clasificadas como no recomendadas.

4. Métricas por clase

Clase	Precisión	Recall	F1-Score	Soporte
No recomendada	0.89	0.96	0.92	25
Recomendada	0.96	0.88	0.92	26
Promedio Macro	0.92	0.92	0.92	51

5. Importancia de las características

Característica	Importancia aproximada
tiempo_estimado_min	87,11 %
numero_transbordos	4,07 %
distancia_km	4,03 %
costo_estimado	2,52 %
numero_estaciones	2,27 %
hora_pico	0 %
nivel_congestion	0 %

El tiempo estimado concentró la mayor importancia del árbol evaluado. Las importancias nulas indican que este árbol no necesitó dividir directamente por esas variables; no implican que carezcan de importancia en sistemas de transporte reales.

6. Evidencias gráficas

El entrenamiento generó los siguientes archivos en graficas/: arbol_decision.png, matriz_confusion.png, rutas_hora_pico.png e importancia_caracteristicas.png. Las imágenes pueden consultarse en el repositorio. Este documento registra los resultados textuales verificados; no incorpora capturas de pantalla no proporcionadas.

7. Prueba de predicción

El comando `py -m ml.predecir_ruta` utilizó una ruta de ejemplo con distancia 13 km, ocho estaciones, un transbordo, congestión 2, tiempo 33 minutos, costo 24 unidades y hora_pico = Resultado observado: RUTA RECOMENDADA. El modelo final se guarda localmente en `modelos/modelo_rutas.joblib`.

8. Pruebas automatizadas

La ejecución `py -m unittest discover -s tests -v` finalizó con `Ran 15 tests ... OK: ocho pruebas del modelo supervisado y siete pruebas del sistema original A*`.

Componente	Verificaciones
Modelo supervisado (8)	Existencia del dataset; cantidad de registros; columnas; ausencia de nulos; etiquetas; hora pico; entrenamiento; predicción válida.
Sistema A* (7)	Conexión directa; estación existente e inexistente; heurística del destino; origen igual a destino; rutas Portal Sur–Portal Norte y Portal Suba–Portal Américas.

9. Interpretación y limitaciones

La evaluación indica que el clasificador reproduce con buena exactitud las etiquetas del conjunto sintético reservado para prueba. No mide precisión sobre rutas reales. Tras la evaluación, el script entrena por separado un modelo final con los 170 registros para utilizarlo en predicciones; la exactitud del 92,16 % corresponde exclusivamente al modelo evaluado sobre la partición de prueba, no a una prueba independiente del modelo final.

10. Conclusiones

Se verificó la generación de datos, el entrenamiento del árbol, el cálculo de métricas, la creación de gráficas, el guardado del modelo y la predicción de una ruta. Las 15 pruebas automatizadas finalizaron satisfactoriamente. La documentación previa de A* se conserva en docs/Pruebas_Sistema_Inteligente.pdf.

11. Referencias y ejecución

Comandos: `py datos/generar_dataset.py`; `py -m ml.entrenar_modelo`; `py -m ml.predecir_ruta`; `py -m unittest discover -s tests -v`. Repositorio: github.com/r0odr1/Sistema-Inteligente-de-Rutas.